

日报三：新版 Chunk 结构设计与实现准备

一、任务名称

日报三

二、任务目的

记录小组成员每日研发进度，确认课题 5「数据格式标准化转换智能体」项目在内容组织深化方向上的推进情况，保证后续开发有明确设计依据和实施路径。

三、今日工作内容

在前一阶段完成内容组织模块初步梳理的基础上，今日开始对新版 chunk 数据结构进行细化设计。

今日工作的重点是明确后续 `chunks.jsonl` 应如何扩展字段，使其既能保持现有成果兼容性，又能更好地服务下游 RAG 入库、训练语料导出和人工检查场景。

本阶段仍以“小范围设计 + 实现准备”为主，暂不进行大规模重构，避免影响现有主流程。

四、小组成员今日进度

1. 王奕力（组长）

今日主要负责新版 chunk 结构的整体设计和开发边界把控。

在现有内容组织流程基础上，初步确定后续 chunk 增强应遵循以下原则：

- 1. 不删除已有字段，保持向后兼容；
- 2. 新增字段应围绕下游消费展开；
- 3. 每个 chunk 必须保留来源信息，便于追溯；
- 4. 标签、摘要、关键词等内容组织信息应结构化表达；
- 5. 后续策略扩展应通过参数控制，而不是写死在流程中。

同时初步规划了新版 chunk 的核心字段，包括 `chunk_id`、`text`、`title_path`、`source_block_ids`、`summary`、`keywords`、`content_tags`、`management_tags`、`quality_tags`、`source_links` 等。

2. 张拓宇（组员）

今日主要负责协助整理 chunk 字段设计细节。

重点对比了现有 chunks 输出和后续下游使用需求，初步确认新版 chunk 中可以将字段分为三类：

第一类是基础字段，用于保证 chunk 可以被正常读取，例如：

```
chunk_id
text
```

```
title
title_path
source_block_ids
```

第二类是内容组织字段，用于增强下游检索和阅读效果，例如：

```
summary
keywords
content_tags
entity_tags
```

第三类是治理与管理字段，用于支持追踪、校验和质量控制，例如：

```
management_tags
quality_tags
source_links
chunk_quality_flags
```

同时协助整理了字段命名规范，尽量保持字段语义清晰，避免后续维护时出现混乱。

3. 朱惠民（组员）

今日主要负责从测试角度评估新版 chunk 结构可能带来的影响。

重点分析了新增字段后需要同步验证的内容，包括：

- `chunks.jsonl` 是否仍能逐行解析；
- 每一行是否仍是合法 JSON；
- 必填字段是否稳定存在；
- source block 回链是否为空或失效；
- package verifier 是否需要增加字段检查；
- downstream smoke 脚本是否能兼容新增字段。

同时初步准备后续测试用例方向，计划先从最小样例开始验证，不直接修改全部生产化评测数据。

五、今日完成情况

今日完成了新版 chunk 数据结构的初步设计，主要成果如下：

1. 明确了 chunks 增强的基本原则：只扩展、不破坏。
2. 初步确定新版 chunk 字段分层：
3. 基础读取字段；
4. 内容组织字段；
5. 治理追踪字段；

6. 质量标记字段。
7. 初步明确后续实现方式：
8. 优先在现有内容组织服务中扩展字段；
9. 不重写 RenderService 和 PackageService；
10. 保持原有成果包文件名和基本目录结构不变；
11. 必要时同步增强 verifier 对 chunks 的检查。
12. 初步确定测试重点：
13. JSONL 格式合法性；
14. 必填字段存在；
15. source links 可追踪；
16. manifest checksum 正确；
17. package smoke test 正常通过。

六、当前问题与风险

当前主要风险是新版 chunk 字段增加后，可能造成内容组织逻辑和成果包校验逻辑不一致。

需要重点关注以下问题：

1. 新字段不能只在 `chunks.jsonl` 中出现，还要在 `content_organization_report.json` 中有对应说明或统计。
2. 如果新增字段成为必填字段，需要同步更新测试和 verifier，否则可能出现生成成功但校验失败的问题。
3. 标签、摘要、关键词目前应以确定性规则为主，不能依赖未配置的大模型能力。
4. `entity_tags` 可以先作为占位或轻量规则字段，不应扩展成完整实体链接系统，避免越界到其他课题。
5. chunk strategy 可以先设计参数接口，不需要一次性实现所有复杂策略。

七、明日计划

明日计划开始进行小范围实现，优先完成新版 chunk 字段的最小可用版本。

计划任务包括：

1. 在现有内容组织服务中增加 chunk 元数据字段；
2. 保证 `chunks.jsonl` 继续正常生成；
3. 增加或调整 chunks 相关测试；
4. 检查 package verifier 是否需要同步修改；

5. 运行一次基础任务流程，确认新增字段不会破坏现有主链路。