

日报九：系统级回归验证与项目收尾准备

一、任务名称

日报九

二、任务目的

记录课题 5「数据格式标准化转换智能体」项目接近完成阶段的研发进展，重点确认核心功能、成果包规范、前端联动、下游消费、回归测试和外部集成能力是否基本稳定，为最终项目收尾做好准备。

三、今日工作内容

在日报八完成成果包规范固化、package verifier 联动和前端展示增强的基础上，今日项目进入系统级回归验证和最终收尾准备阶段。

今日工作的重点不再是新增大量功能，而是对已经完成的核心模块进行整体联调、回归检查和问题收敛，确认系统从 UIR 输入到标准成果包输出的完整链路能够稳定运行。

当前项目主流程已经基本稳定：

```
UIR -> Schema/Template Snapshot -> Candidate Extraction -> Mapping  
-> Transform -> Canonical -> Render -> Content Organization  
-> Validate -> Manifest -> ZIP -> Verify
```

今日围绕该主流程，重点检查字段映射、内容组织、成果包生成、manifest 校验、package verifier、前端工作台、API 调用示例、下游 smoke 脚本和训练语料导出等模块之间的联动情况。

本阶段项目已经接近整体完成，主要工作是查缺补漏、统一文档、补充测试和整理最终交接材料。

四、小组成员今日进度

1. 王奕力（组长）

今日主要负责系统级回归检查和最终收尾任务统筹。

重点对项目整体完成情况进行了梳理，确认目前已经基本完成以下核心能力：

1. UIR 文档导入；
2. Schema 和 Mapping Template 版本治理；
3. 字段候选抽取；
4. 字段自动映射；
5. 映射证据、置信度和风险标记；
6. Transform 转换与字段归一；
7. Canonical Model 构建；
8. 人读 Markdown 和机读 JSON 输出；

9. chunks 内容组织;
10. manifest 清单与 checksum;
11. ZIP 成果包生成;
12. package verifier 校验;
13. Review/Knowledge 人工复核与知识沉淀;
14. 前端 Workbench 演示;
15. API 调用示例和部署说明。

同时，王奕力对项目边界进行了再次确认：当前项目仍然聚焦于课题 5 的标准化转换智能体，不负责原始 PDF、Word、Excel、OCR 解析，不扩展为完整 RAG 问答系统，也不实现模型训练平台。

今日还初步整理了最终收尾阶段需要补充的内容，包括：

最终统一验证记录
已完成功能清单
遗留问题说明
部署和运行说明
API 使用说明
成果包结构说明
最终演示脚本
项目交接说明

2. 张拓宇（组员）

今日主要负责真实样例和下游消费链路的检查。

在前几日完成 `chunks.jsonl`、`content_organization_report.json` 和 `mapping_report.json` 增强后，今日重点检查这些增强内容是否能够稳定进入标准成果包，并能被下游脚本读取。

重点检查内容包括：

`chunks.jsonl` 是否保持合法 JSONL 格式
每个 chunk 是否包含基础 text 字段
`chunk_id` 是否稳定生成
`source_links` 是否能够保留来源信息
`summary` 和 `keywords` 是否正常输出
`content_tags`、`management_tags`、`quality_tags` 是否正常生成
`mapping_report` 是否包含 `matched_by`、`confidence`、`risk_flags` 等信息

同时，张拓宇对训练语料导出和 downstream smoke 脚本进行了检查，确认成果包不仅能被人工下载查看，也能被下游程序消费。

今日还协助整理了成果包协议中的字段说明，重点区分 required、recommended 和 optional 字段，避免后续维护人员不清楚哪些字段是必须存在的。

3. 朱惠民（组员）

今日主要负责测试、回归和稳定性检查。

围绕完整任务流程，重点检查以下路径：

导入 UIR -> 创建任务 -> 执行任务 -> 查看报告
-> 生成成果包 -> 下载 ZIP -> 校验 ZIP -> 下游读取

今日测试关注点包括：

1. 后端接口是否能够正常返回；
2. 任务执行是否稳定；
3. mapping report 是否正常生成；
4. validation report 是否正常生成；
5. content organization report 是否正常生成；
6. manifest checksum 是否正确；
7. package verifier 是否能够区分 error 和 warning；
8. 前端页面是否能够展示关键报告；
9. ZIP 下载是否正常；
10. 下游 smoke 脚本是否能读取 chunks；
11. training corpus export 是否能正常导出。

同时，朱惠民开始整理最终测试记录，准备在日报十中形成最终项目收尾说明。

五、今日完成情况

今日完成了项目接近收尾阶段的系统级检查，主要成果如下：

1. 主链路基本稳定

当前项目从 UIR 输入到标准成果包输出的主流程已经基本跑通，能够完成字段映射、转换、内容组织、校验、打包和下载。

核心链路如下：

UIR 输入
-> Schema/Template 选择
-> 字段候选抽取
-> 字段映射
-> 字段转换
-> Canonical Model
-> JSON/Markdown/Chunks 渲染
-> Schema 校验
-> Manifest 生成
-> ZIP 成果包封装
-> Package Verifier 校验

这说明项目已经具备完整的标准化转换智能体能力。

2. 映射可信度信息基本完善

经过前几日推进，mapping report 已经从简单结果报告逐步增强为可解释报告。

每条字段映射不仅能展示 source field 和 target field，还可以展示：

```
matched_by
confidence
confidence_tier
evidence
risk_flags
review_required
review_required_reason
badcase_filter
```

这样可以帮助人工审核人员快速判断字段映射是否可信，也能支持后续 Review/Knowledge 闭环。

3. 内容组织增强基本完成

新版 chunks 已经能够承载更多下游消费信息，包括：

```
chunk_id
text
title_path
source_block_ids
summary
keywords
content_tags
management_tags
quality_tags
source_links
```

内容组织报告也能够对 chunk 总数、摘要覆盖、关键词覆盖、来源回链和质量标记等内容进行统计。

这使成果包不仅是转换结果，也具备较好的下游入库和检索准备能力。

4. 成果包规范基本固化

当前成果包结构已经基本明确：

```
standard_package.zip
├── manifest.json
├── metadata.json
├── content.json
├── content.md
├── chunks.jsonl
├── canonical.json
└── mapping_report.json
```

- transform_report.json
- validation_report.json
- content_organization_report.json
- verifier_report.json

各文件职责已经基本清晰，能够同时满足人工阅读、机器消费、校验追踪和后续集成需求。

5. Package verifier 基本稳定

今日继续确认 package verifier 应采用 error 和 warning 分级机制。

其中 error 用于标记严重问题，例如必要文件缺失、checksum 不匹配、JSON 无法解析等；warning 用于标记质量问题，例如部分 chunk 缺少 summary、keywords 或 source links。

这种分级方式既保证成果包基础可用，也为后续质量提升保留空间。

6. 前端 Workbench 基本可用

今日检查了前端工作台的主要展示能力，确认用户可以通过页面完成基本操作：

- 导入 UIR
- 创建任务
- 执行任务
- 查看 mapping report
- 查看 validation report
- 查看 content organization report
- 查看 chunks preview
- 查看 package metadata
- 下载 ZIP 成果包
- 查看 review/knowledge 相关信息

前端当前已基本满足演示、调试和人工复核使用场景。

7. 下游消费能力基本验证

今日继续检查 downstream smoke 和 training corpus export 相关能力，确认标准成果包中的 chunks 文件可以被下游程序读取。

这说明项目输出不仅是静态文件，也具备进一步被检索系统、训练语料构建流程或外部系统消费的基础。

六、当前项目完成度判断

按照十次日报的叙事进度，日报九对应项目整体完成度约为：

90%~92%

当前项目已经完成绝大部分核心功能，剩余工作主要集中在：

1. 最终统一验证；
2. 文档收口；
3. 小问题修复；
4. 最终演示流程确认；
5. 交接说明整理；
6. 遗留边界说明；
7. 日报十中的最终总结。

从研发角度看，项目已经进入“功能基本完成，准备最终收尾”的阶段。

七、当前问题与风险

虽然项目已经接近完成，但今日仍然发现或预判以下风险：

1. 文档与代码需要最终同步

项目功能较多，如果文档没有及时更新，后续使用者可能不清楚 API、成果包结构或运行流程。

需要在最终收尾阶段重点检查 README、API 使用示例、部署文档、成果包规范和最终演示脚本。

2. 前端展示还可以继续优化

当前前端已经能展示主要信息，但部分复杂报告仍可能偏向原始 JSON 展示。

后续可以继续优化字段映射表、风险标签、chunk 统计和 package 状态展示，但这属于体验优化，不影响核心功能完成。

3. 部分增强字段质量依赖输入 UIR

例如 title_path、source_links、summary 和 keywords 的质量与上游 UIR 结构有关。

如果输入 UIR 信息不完整，系统应通过 warning 或 quality tag 标记，而不是直接中断任务。

4. LLM fallback 仍需保持安全边界

即使后续启用 LLM suggestion，也必须保持默认关闭、人工复核和不可自动接受的原则。

5. 知识包激活仍需谨慎

Review/Knowledge 闭环虽然已经具备基础能力，但知识包激活仍应受 badcase 保护，避免错误规则污染后续任务。

八、解决措施

针对当前收尾阶段的问题，今日形成以下解决措施：

1. 对所有核心文档进行最终检查，确保文档描述与当前代码能力一致。

2. 对成果包结构进行最终确认，避免不同文档中出现文件名或字段名不一致的问题。
3. 对 verifier 输出进行最终检查，确保 error 和 warning 分级清晰。
4. 对前端演示流程进行完整走查，保证导入、执行、报告查看和 ZIP 下载流程顺畅。
5. 对 API 示例进行复查，保证后端接口路径和参数说明准确。
6. 对剩余问题进行分类：

必须修复：影响主流程运行的问题
建议优化：影响体验但不影响主流程的问题
后续拓展：超出当前项目收尾范围的问题

1. 明确项目边界，防止最终阶段继续扩展范围。

九、今日阶段性成果

今日项目已经从“成果包规范固化与前端联动完善”推进到“系统级回归验证与最终收尾准备”阶段。

阶段性成果可以概括为：

主链路基本稳定
映射可信度增强基本完成
内容组织增强基本完成
成果包规范基本固化
package verifier 基本稳定
前端 Workbench 基本可用
下游消费能力基本验证
最终文档收口方向明确
项目整体完成度达到 90%~92%

整体来看，项目已经基本具备完整交付形态，后续不再需要新增大模块，主要进入最终检查、文档整理和交接阶段。

十、明日计划

明日计划完成最终收尾工作，并形成日报十的项目完成总结。

具体计划如下：

1. 运行最终完整流程验证；
2. 检查后端测试和前端构建情况；
3. 检查成果包 ZIP 生成和 verifier 报告；
4. 检查 API 使用示例是否可用；
5. 检查部署说明是否完整；
6. 整理最终完成的功能清单；

7. 整理当前仍保留的项目边界和后续拓展方向；
8. 准备最终交接说明；
9. 完成日报十，记录项目整体完成情况。