

日报二：内容组织模块梳理与初步设计

一、任务名称

日报二

二、任务目的

确认小组成员每日研发任务完成情况，持续记录课题 5「数据格式标准化转换智能体」项目的研发进度，保证项目开发过程有计划、有记录、可追踪。

三、今日工作内容

在日报一完成项目启动、需求确认和功能边界梳理的基础上，今日开始进入具体开发准备阶段。

今日主要围绕“内容组织深化”方向开展工作，对当前项目中与 chunks、content organization、render、package 相关的模块进行初步阅读和分析，明确后续内容组织能力的改进方向。

本阶段仍然以设计和梳理为主，暂未进行大规模功能改动，重点是先理解现有代码结构，避免在不了解原有主流程的情况下直接修改核心逻辑。

四、小组成员今日进度

1. 王奕力（组长）

今日主要负责组织整体代码结构梳理，并继续把控项目开发方向。

重点阅读和分析了当前项目中与标准化转换主流程相关的模块，确认后续开发仍应围绕以下主线进行：

UIR -> Schema -> Mapping -> Transform -> Canonical -> Render -> Validate -> Manifest -> ZIP

同时初步确认，“内容组织深化”应作为当前阶段的优先任务，主要围绕 chunks 输出结构、标签体系、摘要信息、来源回链和成果包兼容性进行改进，不改变现有主链路的整体执行方式。

2. 张拓宇（组员）

今日主要负责协助梳理现有 chunks 输出结构。

重点查看了当前项目中分段结果、内容组织报告和成果包文件之间的关系，初步确认当前 chunks 已经能够作为下游读取的基础文件，但在字段表达和组织层次上仍有进一步完善空间。

今日初步整理了后续 chunks 字段可能需要补充的内容，包括：

- chunk 唯一标识；
- 来源 block 信息；
- 标题路径；

- 内容标签；
- 管理标签；
- 质量标签；
- 摘要；
- 关键词；
- 原文回链信息。

3. 朱惠民（组员）

今日主要负责从测试和稳定性角度参与模块梳理。

重点关注后续内容组织增强后，如何保证原有 package 生成、manifest 校验、ZIP 下载和 smoke test 不受影响。

初步确认后续新增字段时应遵循向后兼容原则，不能破坏已有 `chunks.jsonl` 的基本结构，也不能导致现有成果包校验失败。

五、今日完成情况

今日完成了内容组织方向的初步准备工作，主要成果如下：

1. 初步阅读了项目中与内容组织相关的代码模块。
2. 明确后续内容组织增强不应重写整个渲染流程，而应在现有 `ChunkOrganizerService` 或相关服务基础上进行渐进式扩展。
3. 初步确定 chunks 后续增强方向：
4. 增加更清晰的 chunk 元数据；
5. 强化标题层级与来源块回链；
6. 补充标签、摘要、关键词等下游消费信息；
7. 保持与现有成果包结构兼容。
8. 初步确认后续测试重点：
9. chunks 文件仍能正常生成；
10. package verifier 仍能通过；
11. manifest 校验和不受影响；
12. 下游 smoke test 能够继续读取成果包。

六、当前问题与风险

当前主要问题是内容组织模块与渲染、打包、校验流程存在关联，如果直接修改 chunks 输出结构，可能影响后续成果包生成和下游读取。

因此后续开发需要注意：

- 新增字段应尽量保持兼容，不删除已有字段；
- 修改 chunks 结构后，需要同步更新 verifier 逻辑；
- 修改成果包内容后，需要同步更新文档说明；
- 不能为了增加内容组织能力而引入完整 RAG 系统；
- 不能让内容组织模块承担原始文档解析或数据清洗职责。

七、明日计划

明日计划在今日梳理基础上，开始进行内容组织增强的具体设计。

计划任务包括：

1. 设计新版 chunk 数据结构草案；
2. 明确哪些字段为必填，哪些字段为可选；
3. 初步设计 chunk strategy 参数，例如 heading-aware、table-protect、parent-child；
4. 编写或调整少量测试用例，先验证 chunks 输出结构；
5. 在不破坏现有流程的前提下，准备进入小范围代码实现。