

日报五：内容组织增强落地与成果包兼容性验证

一、任务名称

日报五

二、任务目的

持续记录课题 5「数据格式标准化转换智能体」项目的研发进展，重点确认内容组织增强功能的实现情况、测试情况以及对成果包生成流程的影响，保证新增功能能够稳定接入现有主流程。

三、今日工作内容

在前几日完成内容组织字段设计、初步实现和校验联动分析的基础上，今日进一步推进了内容组织增强功能的落地工作。

今日主要工作集中在三个方面：

第一，对新版 chunk 输出字段进行实际接入和检查，确认 `chunks.jsonl` 中能够稳定生成更完整的内容组织信息。

第二，对 `content_organization_report.json` 进行同步设计和补充，使其能够反映 chunk 增强后的统计结果，避免出现“chunks 文件已增强，但报告中无法体现”的问题。

第三，对成果包生成、manifest 校验、package verifier 和下游 smoke 脚本进行兼容性检查，确认新增字段不会破坏现有成果包结构和下游读取流程。

本阶段已经从前期设计进入到较明确的实现验证阶段，但仍然坚持不进行大规模重构，优先保证主流程稳定。

四、小组成员今日进度

1. 王奕力（组长）

今日主要负责统筹内容组织增强功能的实现范围，并检查新增功能是否仍然符合课题 5 的项目边界。

重点确认了当前阶段的实现目标：

1. 新版 chunk 字段能够在成果包中稳定输出；
2. 内容组织报告能够展示 chunk 增强后的统计信息；
3. package verifier 能够继续完成成果包完整性校验；
4. downstream smoke 脚本能够继续读取 `chunks.jsonl`；
5. 新增功能不改变原有任务执行主流程。

在实现范围上，今日再次明确本阶段只做“成果包内容组织增强”，不扩展到完整 RAG 系统，也不引入向量数据库或问答模块。项目当前仍然聚焦于课题 5 的标准化转换任务，即把 UIR 转换为 Schema 对齐、可校验、可追溯、可下游消费的标准成果包。

同时，王奕力对当前主流程进行了复查，确认新增内容组织字段仍然位于渲染与打包阶段之间，不影响前置的字段映射、转换、canonical 构建和校验逻辑。

2. 张拓宇（组员）

今日主要负责推进新版 chunk 字段的实际落地和输出检查。

围绕 `chunks.jsonl`，重点检查了以下字段的输出情况：

```
chunk_id
text
title_path
source_block_ids
summary
keywords
content_tags
management_tags
quality_tags
source_links
```

其中，`chunk_id` 用于标识每个 chunk，保证后续报告、人工检查和下游读取时可以定位到具体片段；`title_path` 用于体现 chunk 在文档结构中的位置；`source_block_ids` 和 `source_links` 用于支撑来源追溯；`summary`、`keywords` 和 `content_tags` 用于增强下游检索和阅读效果；`management_tags` 和 `quality_tags` 用于补充治理和质量状态信息。

今日还重点检查了 JSONL 文件格式，确认每一行仍然是一个独立 JSON 对象，新增字段没有破坏原有下游脚本对文本字段的读取方式。

此外，张拓宇初步整理了内容组织报告需要统计的指标，包括：

```
chunk_count
chunks_with_summary
chunks_with_keywords
chunks_with_source_links
chunks_with_content_tags
chunks_with_management_tags
chunks_with_quality_tags
missing_source_link_count
empty_text_chunk_count
```

这些指标后续可以用于快速判断当前成果包的内容组织质量。

3. 朱惠民（组员）

今日主要负责测试验证、成果包兼容性检查和风险排查。

重点围绕以下路径进行检查：

导入 UIR -> 创建任务 -> 执行任务 -> 生成报告 -> 生成 ZIP -> 校验 ZIP -> 下游读取

测试关注点包括：

1. 任务执行是否能够正常完成；
2. `chunks.jsonl` 是否能够正常生成；
3. `content_organization_report.json` 是否能够正常生成；
4. `manifest.json` 是否能够包含更新后的文件 checksum；
5. `verifier_report.json` 是否能够继续输出校验结果；
6. ZIP 包中是否仍然包含所有必要文件；
7. downstream smoke 脚本是否仍能读取 chunk 文本；
8. training corpus export 是否仍能从 chunks 中导出语料。

今日初步确认，新增字段不会天然破坏成果包结构，但测试中仍需要重点关注 verifier 是否对 chunks 字段要求过于严格。如果 verifier 只检查基础字段，则新增字段可以作为兼容增强；如果 verifier 对字段集合有硬编码限制，则需要同步调整为更宽松的校验方式。

五、今日完成情况

今日完成了内容组织增强功能的阶段性落地和基础验证，主要成果如下：

1. 新版 chunk 字段基本接入

当前已围绕下游消费需求，初步完成新版 chunk 字段的接入设计和输出检查。

新版 chunk 相比原有结构，能够提供更多信息，不再只是简单文本片段，而是带有标题层级、来源块、摘要、关键词、标签和质量状态的结构化片段。

2. 内容组织报告同步增强

今日明确 `content_organization_report.json` 不能只展示简单 chunk 列表，而应当承担统计和诊断作用。

后续报告中至少应包含以下几类信息：

- chunk 总数；
- 摘要覆盖情况；
- 关键词覆盖情况；
- 标签覆盖情况；
- 来源回链覆盖情况；
- 质量标记统计；
- 缺失来源信息的 chunk 数量；
- 空文本或过短 chunk 数量。

3. 成果包结构保持稳定

今日确认新增字段不改变成果包核心文件结构，成果包仍然保持以下基本组成：

```
standard_package.zip
├── content.json
```

```
├── content.md
├── chunks.jsonl
├── content_organization_report.json
├── mapping_report.json
├── transform_report.json
├── validation_report.json
├── canonical.json
├── manifest.json
└── verifier_report.json
```

这保证了已有下游脚本和前端下载逻辑不需要发生破坏性修改。

4. 校验逻辑进入联动调整阶段

今日开始对 package verifier 的联动修改进行分析。初步判断 verifier 对新增字段应采用“增强检查”而不是“强制阻断”的方式。

也就是说，必要基础字段缺失应视为错误；增强字段缺失可以先作为 warning 或 quality flag，避免旧数据和部分样例因为增强字段不足而直接失败。

5. 下游读取兼容性得到初步确认

今日初步确认，新增字段不会影响下游 smoke 脚本读取 `text` 字段，也不会影响训练语料导出脚本从 chunks 中提取正文内容。

后续可以进一步增强导出脚本，使其在导出训练语料时携带更多元数据，例如 `keywords`、`content_tags`、`source_links` 和 `schema_id` 等信息。

六、当前实现策略

今日进一步明确了内容组织增强的实现策略。

1. 不重写主流程

当前不重写任务执行主链路，仍保持：

```
UIR -> Schema -> Mapping -> Transform -> Canonical -> Render -> Validate -> Manifest -> ZIP
```

内容组织增强应作为现有渲染与打包流程中的局部增强，不能影响字段映射、transform、validation 等核心步骤。

2. 不破坏旧字段

新增 chunk 字段只能做加法，不能删除或重命名已有字段。
这样可以保证旧的 smoke 脚本、导出脚本和前端展示逻辑继续可用。

3. 报告与数据保持一致

`chunks.jsonl` 中出现的重要增强字段，应在 `content_organization_report.json` 中有对应统计或说明。

例如，如果 chunks 中有 `summary` 字段，报告中应能看到有多少个 chunk 成功生成了 summary；如果有 `source_links` 字段，报告中应能看到来源回链覆盖率。

4. 校验采用分级策略

对 package verifier 来说，后续校验可以分为两层：

第一层是硬性错误，例如：

```
chunks.jsonl 不存在
chunks.jsonl 不是合法 JSONL
chunk 缺少 text 字段
manifest checksum 不匹配
ZIP 缺少必要文件
```

第二层是增强警告，例如：

```
chunk 缺少 summary
chunk 缺少 keywords
chunk 缺少 source_links
chunk 没有 quality_tags
```

这样既能保证成果包可用，又能逐步提高内容组织质量。

5. 标签和摘要保持可复现

当前阶段 `summary`、`keywords` 和 `tags` 仍以确定性规则为主。

原因是确定性规则更容易测试、回放和复现，也更符合治理场景下对稳定性的要求。

如果后续启用 LLM 生成摘要或标签，也必须设置为可选能力，并保留人工复核或质量检查机制。

七、当前问题与风险

今日推进过程中，主要发现以下风险：

1. chunk 字段过多可能导致结构复杂

新增字段有助于下游消费，但字段过多也可能增加维护成本。

后续需要在成果包协议文档中明确哪些字段是必填，哪些字段是推荐，哪些字段是可选。

2. title_path 的准确性依赖上游结构

如果 UIR 或 canonical 中没有足够清晰的标题层级，`title_path` 只能保守生成。

这类情况不应直接判定失败，而应通过 quality tag 标记。

3. source_links 覆盖率可能不稳定

部分样例可能缺少完整 source anchor 或 block id，导致 source links 不完整。

后续应在报告中统计缺失数量，并在 chunk 级别记录 `missing_source_link` 之类的质量标记。

4. 摘要和关键词质量有限

当前使用规则化方式生成摘要和关键词，稳定性较好，但表达质量可能一般。

后续可以考虑增加可选 LLM 模式，但不能默认启用，也不能直接自动接受高风险结果。

5. verifier 修改需要谨慎

如果 verifier 过度严格，可能导致旧成果包或部分样例无法通过；如果过度宽松，又无法发现真实问题。

因此后续需要采用 error 与 warning 分级。

八、解决措施

针对当前风险，今日形成以下解决措施：

1. 制定 chunk 字段分级规范：

```
required: chunk_id, text
recommended: title_path, source_block_ids, source_links
optional: summary, keywords, content_tags, management_tags, quality_tags, entity_tags
```

1. 在 `content_organization_report.json` 中增加覆盖统计，而不是只依赖人工打开 chunks 文件检查。
2. 对来源缺失、标题路径缺失、文本过短等问题使用 quality tag 标记，不直接中断任务。
3. package verifier 增加 warning 机制，避免增强字段缺失导致成果包不可用。
4. 保持所有新增内容可复现，不引入默认 LLM 调用。
5. 后续补充成果包协议文档，明确新版 `chunks.jsonl` 的字段含义和兼容策略。

九、今日阶段性成果

今日项目已经从“内容组织增强的初步实现”推进到“功能基本落地并开始进行成果包兼容性验证”的阶段。

当前阶段性成果可以概括为：

```
新版 chunk 字段设计基本确定
chunks.jsonl 增强方向基本落地
content_organization_report 统计方向明确
package verifier 联动策略明确
downstream smoke 兼容性初步确认
成果包结构保持稳定
```

整体上，今日工作使项目在课题 5 的“面向下游的内容组织”和“标准成果包封装”两个方向上都有了更实质性的推进。

十、明日计划

明日计划继续推进内容组织增强的测试收尾和文档固化工作，同时开始为“映射可信度增强”做准备。

具体计划如下：

1. 补充 chunks 输出结构相关测试；
2. 检查所有样例任务生成的 `chunks.jsonl` 是否格式合法；
3. 检查 `content_organization_report.json` 的统计是否与 chunks 文件一致；
4. 完成 package verifier 的 error/warning 分级设计；
5. 运行完整任务流程，确认成果包 ZIP 可正常生成和下载；
6. 运行 downstream smoke 脚本，确认下游读取正常；
7. 初步整理新版 chunks 字段说明；
8. 开始阅读 mapping report 相关代码，为后续“字段映射可信度与证据增强”做准备。