

日报八：成果包规范固化与前端联动完善

一、任务名称

日报八

二、任务目的

记录课题 5「数据格式标准化转换智能体」项目的每日研发进展，重点跟踪字段映射可信度增强后的联动完善情况，以及标准成果包规范、package verifier、API 和前端展示的同步调整情况。

三、今日工作内容

在日报七完成字段映射可信度增强设计与部分实现的基础上，今日继续推进成果包规范化和系统联动工作。

今日主要围绕三个方向展开：

第一，对增强后的 `mapping_report.json`、`chunks.jsonl`、`content_organization_report.json` 等核心文件进行统一梳理，确认成果包中各类文件的职责边界和字段含义。

第二，对 package verifier 进行联动检查，使其能够识别成果包中的必要文件、校验 manifest checksum，并对增强字段采用 error 与 warning 分级策略。

第三，对前端工作台和 API 展示进行同步调整，确保用户能够更直观地查看字段映射证据、风险标记、复核原因、内容组织统计和成果包下载信息。

本阶段项目已经从“核心功能实现”逐步进入“成果规范固化与交互完善”阶段。

四、小组成员今日进度

1. 王奕力（组长）

今日主要负责整体成果包规范的梳理和模块联动把控。

在前几日完成内容组织增强和映射可信度增强后，项目输出文件数量和字段信息明显增加。为了避免成果包结构混乱，今日重点对标准成果包的组成进行了统一整理。

当前成果包核心结构初步确定如下：

```
` ``text id="0itz7s" standard_package.zip |—— manifest.json |—— metadata.json |—— content.json
|—— content.md |—— chunks.jsonl |—— canonical.json |—— mapping_report.json |——
transform_report.json |—— validation_report.json |—— content_organization_report.json |——
verifier_report.json
```

其中，`content.json` 和 `content.md` 分别面向机器读取和人工阅读；`chunks.jsonl` 面向下游 RAG 入库或训练语料导出；`mapping\_report.json` 用于记录字段映射过程和可信度信息；

`validation\_report.json` 用于记录 Schema 校验结果；`manifest.json` 用于记录文件清单和校验和；`verifier\_report.json` 用于记录成果包完整性检查结果。

同时，王奕力进一步明确了成果包规范化原则：成果包既要能让人看懂，也要能让程序稳定读取；既要保留转换结果，也要保留转换过程中的证据、报告和追踪信息。

2. 张拓宇（组员）

今日主要负责成果包字段和报告内容的同步检查。

重点检查了增强后的 mapping report 是否能够在成果包中稳定输出，并确认每条 mapping decision 应包含以下关键信息：

```
```text id="cp9g37"
source_field
target_field
matched_by
confidence
confidence_tier
evidence
risk_flags
review_required
review_required_reason
badcase_filter
```

这些字段能够帮助后续人工审核人员判断字段映射结果是否可靠。

同时，张拓宇继续检查了 `chunks.jsonl` 与 `content_organization_report.json` 的一致性，确认 chunks 中新增的摘要、关键词、标签、来源回链和质量标记，应当在内容组织报告中有对应统计。

今日还初步整理了成果包字段分级思路：

```text id="i48b5b" required: 成果包必须存在，否则 verifier 报 error recommended: 推荐存在，缺失时 verifier 报 warning optional: 增强字段，缺失时不影响成果包基础可用性

通过字段分级，可以避免增强功能对旧数据或部分样例造成过度影响。

3. 朱惠民（组员）

今日主要负责 verifier 联动测试和前端展示影响分析。

在 verifier 方面，重点检查了以下内容：

1. 成果包必要文件是否完整；
2. manifest 中记录的文件是否真实存在；
3. checksum 是否能够正确匹配；
4. JSON 文件是否能够正常解析；
5. `chunks.jsonl` 是否仍然保持合法 JSONL 格式；
6. mapping report 中新增字段是否不会导致校验异常；

7. warning 信息是否能够正确记录，而不是直接中断任务。

在前端方面，朱惠民重点关注 mapping report 展示区域和 package 信息展示区域是否需要同步调整。

当前前端展示可以优先增强以下内容：

```
```text id="0qiuf9"
映射策略 matched_by
置信度 confidence
风险标签 risk_flags
是否需要复核 review_required
复核原因 review_required_reason
成果包文件列表
package verifier 状态
ZIP 下载入口
```

这样可以让用户不需要直接打开 JSON 文件，也能在页面上快速了解转换结果质量和成果包状态。

## 五、今日完成情况

今日完成了成果包规范化和系统联动方向的重要推进，主要成果如下：

### 1. 成果包核心结构进一步明确

今日统一梳理了标准成果包中的核心文件，明确了每类文件的用途。

成果包不再只是简单输出转换结果，而是包含：

- 转换后的结构化内容；
- 人工可读内容；
- 下游可消费 chunks；
- 字段映射报告；
- 转换报告；
- 校验报告；
- 内容组织报告；
- manifest 清单；
- verifier 校验结果；
- 元数据说明。

这使成果包具备更强的可追踪性和可集成性。

### 2. Mapping report 增强结果纳入成果包

今日确认字段映射可信度增强后的信息应稳定写入 `mapping_report.json`。

后续成果包中的 mapping report 不仅展示映射结果，还展示映射策略、置信度、证据、风险标记和复核原因。

这使字段映射结果具备更好的可解释性。

### 3. Package verifier 分级校验方向明确

今日进一步确认 verifier 应采用 error 与 warning 分级策略。

其中 error 代表成果包不可用或存在严重问题，例如必要文件缺失、checksum 不匹配、JSON 无法解析等。

warning 代表成果包基础可用，但存在质量改进空间，例如部分 chunk 缺少 summary、source links、keywords 或 quality tags。

这种分级方式能够兼顾稳定性和质量提升。

### 4. 前端展示增强方向明确

今日明确前端不应只展示原始 JSON，而应提供更友好的可视化信息。

前端可以在 mapping report 区域展示字段映射表，在 package 区域展示成果包状态，在 content organization 区域展示 chunk 统计信息。

这样可以降低用户理解系统输出的成本。

### 5. API 与文档同步更新方向明确

今日确认后需同步更新 API 使用说明和成果包规范文档，避免代码能力已经变化，但文档仍停留在旧版本。

尤其是以下内容需要同步：

``text id="vrcqdt" mapping\_report 字段说明 chunks.jsonl 字段说明 content\_organization\_report 统计说明 manifest 字段说明 verifier\_report error/warning 说明 package download 接口说明

#### ## 六、当前实现策略

今日进一步明确成果包规范化和联动完善的实现策略。

##### ### 1. 成果包结构保持稳定

不改变核心文件名称，不随意调整目录结构。  
新增信息优先以字段扩展和报告增强方式实现。

##### ### 2. 文件职责清晰

每个成果包文件应有明确职责，避免多个文件重复承担同一功能。

例如，`content.json` 负责结构化内容，`mapping\_report.json` 负责映射证据，  
`validation\_report.json` 负责 Schema 校验，`manifest.json` 负责文件清单和 checksum。

##### ### 3. 校验分级处理

verifier 对基础可用性问题报 error，对质量增强问题报 warning。

这样既能保证成果包可靠，又能避免因增强字段缺失导致旧流程不可用。

#### ### 4. 前端先做最小增强

前端暂时不做复杂交互重构，优先增强关键信息展示。

例如增加映射策略、置信度、风险标签、复核原因和成果包状态展示。

#### ### 5. 文档与代码同步

每次新增成果包字段或校验规则后，应同步更新对应文档，避免后续维护成本增加。

### ## 七、当前问题与风险

今日发现或预判的主要问题如下：

#### ### 1. 成果包字段较多，容易造成理解成本上升

随着 mapping report 和 chunks 增强，成果包字段明显增多。  
后续需要通过 `package\_spec.md` 或类似文档明确字段含义和必填等级。

#### ### 2. Verifier 规则过严或过松都会有问题

如果过严，可能导致部分旧成果包或轻量样例无法通过；如果过松，又无法发现真实问题。

因此 verifier 需要保持 error/warning 分级，而不是所有问题都直接判失败。

#### ### 3. 前端展示可能跟不上后端字段变化

如果后端报告字段更新，但前端仍然只展示原始 JSON，会影响使用体验。

后续应至少完成最小展示增强，让用户能快速看到关键结果。

#### ### 4. 成果包规范需要保持版本意识

随着字段不断扩展，成果包需要有版本号，避免后续不同版本 package 混用时难以兼容。

#### ### 5. 下游脚本需要保持兼容

downstream smoke 和 training corpus export 应继续能读取基础字段，不能因为新增字段而失败。

### ## 八、解决措施

针对上述问题，今日形成以下解决措施：

#### 1. 制定成果包字段分级：

```
```text
required: 缺失则 error
recommended: 缺失则 warning
optional: 缺失不影响基础可用
```

...

2. 在 manifest 或 metadata 中记录 package schema version。

3. verifier 输出中明确区分：

```
```text
errors
warnings
summary
checked_files
checksum_results
```
```

4. 前端 mapping 区域优先增加字段映射表，而不是只展示 JSON。

5. 前端 package 区域展示 verifier 状态和 ZIP 下载入口。

6. 文档中补充成果包结构说明和字段说明。

7. 下游脚本继续只依赖稳定基础字段，增强字段作为附加信息读取。

九、今日阶段性成果

今日项目从“字段映射可信度增强”推进到“成果包规范固化与系统联动完善”阶段。

阶段性成果可以概括为：

```
```text id="r0acta"
成果包核心结构明确
mapping report 增强信息纳入成果包
package verifier error/warning 分级方向明确
前端展示增强范围明确
API 与文档同步更新方向明确
下游读取兼容策略明确
```
```

整体来看，项目已经不只是能完成标准化转换，而是在向“可交付、可验证、可集成”的标准成果包系统推进。

按照当前十次日报的叙事进度，日报八大约对应项目整体完成度的 80%~85%。

十、明日计划

明日计划继续推进系统级联动和质量评估方向的工作。

具体计划如下：

1. 完善 `package_spec.md` 中的成果包结构说明；

2. 检查 manifest 和 metadata 中是否需要增加 package version;
3. 完善 package verifier 的 error/warning 输出;
4. 检查前端 mapping report 区域展示效果;
5. 检查前端 package metadata 和 ZIP 下载展示效果;
6. 运行完整任务流程, 确认成果包生成、校验和下载正常;
7. 运行 downstream smoke 和 training corpus export;
8. 开始准备 Evaluation Center、真实数据评测和回归门禁相关内容。