

日报六：内容组织测试收尾与映射可信度增强准备

一、任务名称

日报六

二、任务目的

记录课题 5「数据格式标准化转换智能体」项目的每日研发进展，确认内容组织增强功能的测试收尾情况，并为下一阶段字段映射可信度增强工作做好准备。

三、今日工作内容

在日报五完成内容组织增强基本落地和成果包兼容性验证的基础上，今日主要开展两方面工作：

第一，对内容组织增强功能进行测试收尾，重点检查新版 `chunks.jsonl`、`content_organization_report.json`、成果包 `manifest`、`package verifier` 和 `downstream smoke` 脚本之间是否能够正常联动。

第二，开始进入下一阶段“字段映射可信度增强”的准备工作，初步阅读 `mapping report`、`mapping service`、`review queue` 和 `knowledge pack` 相关逻辑，准备后续为字段映射结果增加证据说明、风险标记和更清晰的人工复核信息。

今日工作标志着项目重点从“内容组织深化”逐步过渡到“字段映射可信度与人审体验增强”。

四、小组成员今日进度

1. 王奕力（组长）

今日主要负责统筹内容组织增强的阶段性收尾，并组织下一阶段映射可信度增强方向的任务拆分。

在内容组织方面，重点确认新增 `chunk` 字段没有改变原有成果包结构，仍然能够保持标准输出：

```
content.json
content.md
chunks.jsonl
content_organization_report.json
mapping_report.json
transform_report.json
validation_report.json
canonical.json
manifest.json
verifier_report.json
```

同时检查了内容组织增强后的整体边界，确认当前实现仍然服务于课题 5 的“面向下游的内容组织”和“标准成果包封装”，没有扩展成完整 RAG 系统，也没有引入向量数据库、问答模块或模型训练模块。

在下一阶段准备方面，王奕力初步确定字段映射可信度增强的目标：让每个字段映射结果不仅能说明“源字段映射到了哪个目标字段”，还要说明“为什么这样映射、依据是什么、置信度如何、是否存在风险、是否需要人工复核”。

2. 张拓宇（组员）

今日主要负责继续检查内容组织增强后的输出结果，并整理后续映射报告需要补充的信息。

在 chunks 检查方面，重点关注以下字段是否稳定输出：

```
chunk_id
text
title_path
source_block_ids
summary
keywords
content_tags
management_tags
quality_tags
source_links
```

同时对 `content_organization_report.json` 中的统计字段进行核对，确认报告中能够体现 chunk 总数、摘要覆盖情况、关键词覆盖情况、来源回链情况和质量标签情况。

在映射可信度增强准备方面，张拓宇开始梳理 `mapping_report.json` 当前已有字段，并初步整理后续可能需要新增的 evidence 信息，例如：

```
matched_by
source_field
target_field
confidence
evidence_text
risk_flags
review_required_reason
badcase_blocked
```

这些字段后续可以帮助人工审核人员快速判断一个映射结果是否可信。

3. 朱惠民（组员）

今日主要负责测试验证和回归检查。

围绕内容组织增强后的完整链路，重点检查以下流程是否稳定：

```
导入 UIR -> 创建任务 -> 执行任务 -> 生成报告 -> 生成 ZIP -> 校验 ZIP -> 下游读取
```

测试关注点包括：

1. `chunks.jsonl` 是否仍为合法 JSONL；
2. 每个 chunk 是否保留必要基础字段；
3. `content_organization_report.json` 是否正常生成；
4. `manifest.json` 中 checksum 是否与实际文件一致；
5. `verifier_report.json` 是否能够区分 error 和 warning；
6. downstream smoke 脚本是否能够继续读取 chunk 文本；
7. training corpus export 是否仍能导出训练语料 JSONL；
8. 新增字段是否影响前端 chunk preview 展示。

同时，朱惠民开始从测试角度评估后续映射可信度增强可能带来的影响，特别是新增 evidence 字段后，mapping report 的结构是否需要同步更新测试。

五、今日完成情况

今日完成了内容组织增强方向的阶段性测试收尾，并开始进入映射可信度增强的前期准备阶段，主要成果如下：

1. 内容组织增强基本稳定

经过检查，新版 chunk 字段能够作为增强信息输出，未破坏原有 `chunks.jsonl` 的基础读取方式。

新增字段主要用于提高下游消费能力和人工检查效率，包括标题路径、来源块、摘要、关键词、内容标签、管理标签、质量标签和来源回链。

2. 内容组织报告能够反映增强结果

今日确认 `content_organization_report.json` 应继续承担统计和诊断作用，而不仅是简单记录 chunk 生成结果。

报告中需要反映以下信息：

```
chunk_count
chunks_with_summary
chunks_with_keywords
chunks_with_source_links
chunks_with_content_tags
chunks_with_management_tags
chunks_with_quality_tags
missing_source_link_count
empty_text_chunk_count
```

这样可以让开发人员和审核人员快速判断成果包的内容组织质量。

3. package verifier 联动方向明确

今日继续确认 verifier 应采用 error 和 warning 分级机制。

硬性错误主要包括：

```
必要文件缺失
manifest checksum 不匹配
chunks.jsonl 非法
chunk 缺少基础 text 字段
JSON 文件无法解析
```

增强警告主要包括：

```
chunk 缺少 summary
chunk 缺少 keywords
chunk 缺少 source_links
chunk 缺少 title_path
chunk 存在 quality_tags
```

这种分级方式既能保证成果包基础可用，又能逐步暴露内容组织质量问题。

4. 下游读取兼容性继续保持

今日确认新增 chunk 字段不应影响 downstream smoke 脚本和 training corpus export 脚本的基础运行。

后续可以考虑让 training corpus export 在导出时附带更多元数据，例如：

```
chunk_id
schema_id
template_id
content_tags
keywords
source_links
quality_tags
```

但这属于增强功能，不应影响当前基础导出。

5. 映射可信度增强进入准备阶段

今日开始梳理下一阶段需要增强的 mapping report 信息。

当前后续目标是让字段映射报告从“结果型报告”进一步升级为“可解释报告”，不仅显示映射结果，还显示每条映射背后的依据、策略、置信度和风险状态。

六、映射可信度增强初步设计

今日初步确定下一阶段字段映射可信度增强的设计方向。

1. 每条映射需要说明映射策略

后续 mapping report 中应清楚标记每条映射来自哪种策略，例如：

```
exact
alias
regex
type
fuzzy
llm_suggestion
review_required
failed
```

这样可以区分确定性高的规则映射和需要人工关注的疑难映射。

2. 每条映射需要保留证据文本

后续可以增加 `evidence_text` 或 `evidence` 字段，用于说明该映射为什么成立。

例如：

```
源字段名称与目标字段别名匹配
源字段命中模板 regex 规则
源字段类型与目标字段类型一致
源字段与目标字段名称相似度较高，但置信度不足，需要人工复核
```

3. 每条映射需要风险标记

后续可以增加 `risk_flags` 字段，用于标记潜在风险，例如：

```
low_confidence
fuzzy_match
type_mismatch
confusing_alias
badcase_related
llm_generated
review_required
```

这样人工审核时可以优先处理高风险映射。

4. Review Required 原因需要更明确

当前如果某些映射进入人工复核，后续报告中应明确说明原因，例如：

```
置信度低于阈值
多个候选字段冲突
```

命中 badcase 保护规则
LLM 仅提供建议，不能自动接受
必填字段未找到可靠来源

这样可以减少人工审核时的理解成本。

5. 与 Knowledge Pack 保持闭环

后续人工确认后的映射结果仍应通过 Review/Knowledge 流程沉淀为候选知识，不应直接修改基础模板。

只有被接受并激活的 knowledge pack 才能影响后续新任务，从而保持历史任务快照不被污染。

七、当前问题与风险

今日发现或预判的主要问题如下：

1. mapping report 结构可能需要调整

如果新增 evidence、risk_flags、review_required_reason 等字段，需要确认前端展示、测试用例和文档说明是否同步更新。

2. 不能让报告变得过于复杂

映射可信度增强的目标是提升可解释性，而不是堆叠大量无用字段。

后续需要区分核心字段和辅助字段，避免 mapping report 变得难以阅读。

3. LLM suggestion 必须保持人工复核

如果后续启用可选 LLM fallback，LLM 只能提供建议，不得自动接受映射结果。

所有 LLM 相关建议都应标记为 `review_required`，并记录模型、置信度、原因和哈希信息。

4. badcase 保护不能被知识包绕过

后续如果人工确认了某个 alias，但该 alias 与 badcase 冲突，则 knowledge pack 激活前仍应被阻止或标记为高风险。

5. 前端展示需要同步规划

如果后端 mapping report 增加了可信度和证据信息，前端应提供更直观的展示方式，例如字段映射表、风险标签、置信度标记和审核按钮。

八、解决措施

针对当前风险，今日初步形成以下解决思路：

1. mapping report 新增字段采用向后兼容方式，不删除原有字段。

2. evidence 信息先以简洁文本和结构化字段并存的方式输出。
3. risk_flags 使用数组形式，便于后续扩展。
4. review_required_reason 使用明确枚举或固定文本，减少前端处理难度。
5. LLM suggestion 继续保持默认关闭和人工复核策略。
6. badcase 检查继续作为 regression gate，不因知识包激活而绕过。
7. 前端展示先做最小增强：在 mapping report 区域增加策略、置信度、风险标签和复核原因展示。

九、今日阶段性成果

今日项目从“内容组织增强落地验证”推进到“内容组织测试收尾 + 映射可信度增强准备”的阶段。

阶段性成果可以概括为：

内容组织增强基本稳定
chunks 输出与报告统计关系明确
package verifier 分级校验方向明确
下游读取兼容性继续保持
mapping report 增强字段初步确定
映射证据与风险标记设计开始成型
下一阶段开发重点明确

整体来看，项目已经完成了内容组织方向的一轮主要增强，下一步将围绕字段映射可信度、人审效率和知识包闭环继续深入。

十、明日计划

明日计划正式开始推进字段映射可信度增强的具体实现。

具体计划如下：

1. 阅读 MappingService 中各映射策略的输出结构；
2. 明确 mapping report 当前字段与新增字段的兼容方式；
3. 为每种映射策略补充 matched_by 或 strategy 标记；
4. 为低置信度、fuzzy、LLM suggestion、badcase 命中等情况补充 risk_flags；
5. 为 review_required 项补充明确原因；
6. 增加 mapping report 相关测试；
7. 检查前端 mapping report 展示区域是否需要同步调整；
8. 确保新增可信度字段不会破坏 Review/Knowledge 现有闭环。