

# 日报四：内容组织字段初步实现与校验联动

## 一、任务名称

日报四

## 二、任务目的

记录小组成员在课题 5「数据格式标准化转换智能体」项目中的每日研发进展，重点跟踪内容组织深化方向的实际实现情况，确认新增功能是否能够在不破坏原有主流程的前提下稳定运行。

## 三、今日工作内容

在日报三完成新版 chunk 结构设计与实现准备的基础上，今日开始进行小范围代码实现与联动检查。

今日工作的重点是将前期设计的部分 chunk 扩展字段落到现有内容组织流程中，优先实现对下游消费价值较高、同时风险较低的字段，例如 `chunk_id`、`title_path`、`source_block_ids`、`summary`、`keywords`、`content_tags`、`management_tags`、`quality_tags` 和 `source_links`。

本阶段仍然坚持渐进式开发原则，不对 `RenderService`、`PackageService` 和主任务执行流程进行大规模重构，而是在现有内容组织服务基础上扩展输出字段，并同步检查成果包校验逻辑是否需要调整。

## 四、小组成员今日进度

### 1. 王奕力（组长）

今日主要负责整体实现方案把控和内容组织服务的修改方向确认。

在前期设计基础上，进一步明确了本阶段实现范围：

1. 优先扩展 chunk 输出字段；
2. 保持 `chunks.jsonl` 文件名和 JSONL 输出格式不变；
3. 不删除已有字段，避免影响下游 `smoke` 脚本；
4. 不引入完整 RAG 系统，仅增强成果包的可消费性；
5. 不启用大模型生成摘要，当前摘要仍以确定性规则或轻量规则为主。

同时对内容组织服务的职责边界进行了再次确认：内容组织模块只负责基于已有 `UIR/canonical/render` 结果生成分段、标签、摘要和回链信息，不负责原始文件解析、清洗、归一或实体链接。

今日还初步检查了内容组织服务与任务执行管线之间的关系，确认新增字段应在 `package` 生成前完成，使最终 ZIP 包中的 `chunks.jsonl` 和 `content_organization_report.json` 能够保持一致。

### 2. 张拓宇（组员）

今日主要负责新版 chunk 字段的具体整理和初步实现辅助。

重点推进了以下字段的设计落地：

```
chunk_id
title_path
source_block_ids
summary
keywords
content_tags
management_tags
quality_tags
source_links
```

其中：

- `chunk_id` 用于保证每个 chunk 具备稳定标识；
- `title_path` 用于记录 chunk 所属的标题层级；
- `source_block_ids` 用于保留来源内容块信息；
- `summary` 用于给出 chunk 级简要摘要；
- `keywords` 用于辅助下游检索和人工预览；
- `content_tags` 用于表达内容主题；
- `management_tags` 用于表达文档类型、处理阶段等管理信息；
- `quality_tags` 用于表达 chunk 是否存在过短、来源缺失、内容为空等质量状态；
- `source_links` 用于保留原文回链信息，方便后续追溯。

同时初步整理了内容组织报告中应补充的统计信息，例如 chunk 总数、带来源回链的 chunk 数量、带摘要的 chunk 数量、带标签的 chunk 数量、存在质量标记的 chunk 数量等。

### 3. 朱惠民（组员）

今日主要负责测试影响分析和校验逻辑检查。

重点检查了新增 chunk 字段可能影响的几个位置：

1. `chunks.jsonl` 是否仍保持一行一个 JSON 对象；
2. 新增字段是否会导致 JSON 序列化失败；
3. package verifier 是否仍能识别成果包；
4. manifest 中的 checksum 是否会随着文件变化正常重新计算；
5. downstream smoke 脚本是否能忽略新增字段并正常读取文本内容；
6. training corpus export 脚本是否可以继续从 chunks 中提取训练语料。

同时初步确认，新增字段应尽量采用“宽松兼容”策略：已有脚本只依赖基础字段，新字段作为增强信息存在，不应强制所有下游脚本立即使用。

## 五、今日完成情况

今日完成了内容组织增强方向的第一轮小范围实现和联动设计，主要成果如下：

1. 明确了新版 chunk 字段的最小实现集合。
2. 初步完成或准备完成部分字段在内容组织流程中的输出。

3. 明确 `content_organization_report.json` 需要同步反映新增字段的统计情况，避免报告与实际 `chunks` 输出脱节。

4. 初步确认新增字段不会改变成果包的基本目录结构，仍保持以下核心文件：

```
content.json
content.md
chunks.jsonl
content_organization_report.json
mapping_report.json
transform_report.json
validation_report.json
canonical.json
manifest.json
verifier_report.json
```

1. 初步确认 `package verifier` 和 `downstream smoke` 脚本应保持向后兼容，只在必要时增加增强字段检查。

2. 明确本阶段摘要、关键词、标签生成仍采用确定性或轻量规则方式，暂不依赖外部大模型。

## 六、实现原则与技术约束

今日进一步明确了后续实现必须遵守的技术约束：

### 1. 保持主流程稳定

当前项目主流程仍然保持为：

```
UIR -> Schema -> Mapping -> Transform -> Canonical -> Render -> Validate -> Manifest -> ZIP
```

内容组织增强只能作为主流程中的增强环节，不能改变任务执行的整体顺序。

### 2. 保持成果包兼容

成果包结构不应因为新增字段而发生破坏性变化。

`chunks.jsonl` 可以增加字段，但不能删除原有字段；`manifest.json` 和 `verifier_report.json` 需要继续正常生成。

### 3. 标签和摘要先规则化实现

当前阶段不使用大模型自动生成标签或摘要，避免引入不可控结果。

如果后续需要 LLM fallback，也必须保持人工复核，不允许自动写入高风险结果。

### 4. 实体标签暂不做完整实体链接

`entity_tags` 可以先保留为空数组、占位字段或轻量规则抽取结果。

本阶段不实现完整实体链接、实体消歧或知识库对齐，避免越界到其他课题。

## 5. 测试优先覆盖稳定性

本阶段测试重点不是追求复杂指标，而是确认新增字段不会破坏原有流程。

优先保证导入、建任务、执行、生成报告、生成 ZIP、校验 ZIP、下游读取这条路径能继续跑通。

## 七、当前问题与风险

今日发现或预判的主要问题如下：

1. 新增字段后，`chunks.jsonl` 文件内容会发生变化，需要确认 manifest checksum 重新计算逻辑正常。
2. 如果 package verifier 对 chunks 字段要求过于严格，可能导致旧包或旧测试失败，因此 verifier 增强需要谨慎。
3. `summary` 和 `keywords` 如果完全基于规则生成，可能存在质量有限的问题，但当前阶段更重视稳定性和可复现性。
4. `title_path` 的准确性依赖上游 block 或 canonical 中的标题结构，如果上游标题信息不足，只能生成较保守的标题路径。
5. `source_links` 的完整性依赖来源 block 信息，如果部分 UIR 样本缺少来源锚点，需要在 quality tags 中标记，而不是直接报错中断流程。
6. 内容组织报告需要与 chunks 输出保持一致，否则可能出现“chunks 已增强，但报告看不出来”的问题。

## 八、解决思路

针对上述问题，今日初步形成以下解决思路：

1. 对新增字段采用可选增强方式，不破坏已有字段。
2. 对来源信息缺失的 chunk，不强行失败，而是添加 `quality_tags` 或 `chunk_quality_flags`。
3. 对 summary、keywords、tags 采用确定性规则生成，保证同样输入下结果可复现。
4. 在 `content_organization_report.json` 中增加字段覆盖统计，例如：

```
chunk_count
chunks_with_summary
chunks_with_keywords
chunks_with_source_links
chunks_with_quality_tags
missing_source_link_count
```

1. 在测试中增加对 JSONL 格式合法性和必填字段的检查。

2. package verifier 暂时只检查核心字段，增强字段可以先做存在性或格式检查，不作为强制失败条件。

## 九、今日完成情况总结

今日项目从“设计准备”推进到了“初步实现与联动检查”阶段。

整体来看，内容组织增强方向已经具备较清晰的实施路径：先扩展 chunk 数据结构，再同步完善内容组织报告，最后调整测试和 verifier，确保成果包仍可被下游稳定读取。

本阶段没有改变项目边界，没有引入原始文件解析、完整 RAG、模型训练或自动化 LLM 决策，仍然保持在课题 5 的标准化转换范围内。

## 十、明日计划

明日计划继续推进内容组织增强的代码实现和测试验证。

具体计划包括：

1. 完成新版 chunk 字段的最小实现版本；
2. 检查 chunks.jsonl 中每个 chunk 是否包含预期字段；
3. 更新 content\_organization\_report.json 的统计信息；
4. 增加或调整 chunks 相关单元测试；
5. 运行一次完整任务执行流程；
6. 检查生成的 ZIP 成果包是否包含所有必要文件；
7. 运行 package verifier，确认校验通过；
8. 尝试运行 downstream smoke 脚本，确认下游读取不受影响；
9. 记录实现过程中发现的问题，为后续进一步优化内容组织策略做准备。